

Seminario de Investigación II · Universidad de Lima

Informe de la Etapa 1

Ampliación del dataset mediante pseudo-etiquetado semisupervisado

Proyecto: Detección no invasiva de madurez y defectos en paltas Hass con visión computacional en dispositivos edge

Autores: Fabrizio Vargas · Dylann Rojas

Asesor: Javier More Sánchez

Fecha: 24 de septiembre de 2026

Resumen

La Etapa 1 tenía como objetivo ampliar el conjunto de entrenamiento usando el propio modelo para etiquetar imágenes sin anotar, y medir si ese aumento de datos mejora el desempeño. Antes de ejecutarla fue necesario reconstruir en Python, sin Roboflow, el pipeline de Seminario I. Esa reconstrucción destapó dos problemas en la base heredada: una fuga de datos en la partición original (198 de 415 paltas tenían fotos repartidas entre entrenamiento y prueba) y 51 anotaciones defectuosas generadas por fallas de SAM2. Ambos se corrigieron antes de entrenar.

Sobre esa base se entrenó un modelo YOLOv8s-seg multitarea que segmenta palta y defectos y, con un cabezal adicional sobre el backbone compartido, clasifica la madurez en cinco niveles. Con este modelo se pseudo-etiquetaron 9,892 fotos de paltas de entrenamiento. Una regla de aceptación calibrada en validación admitió 4,623 de ellas, con lo que el conjunto de entrenamiento pasó de 852 a 5,475 imágenes.

El modelo reentrenado (ronda 1) mejoró la clasificación de madurez en test de 63.9% a 74.1% de exactitud, y el F1 macro de 0.633 a 0.737. Esa mejora del F1 es estadísticamente significativa en un bootstrap pareado por fruto. La segmentación y la categorización OCDE se mantuvieron sin diferencias distinguibles del ruido. La explicación es consistente con los datos: la madurez de las imágenes nuevas es una etiqueta real, mientras que las máscaras de defecto aceptadas eran precisas pero incompletas.

Indicador (test, 108 imágenes, 39 paltas)	Modelo base	Ronda 1	Diferencia
Madurez, exactitud	63.9%	74.1%	+10.2 pts (IC 95%: 0.0 a +20.0)
Madurez, F1 macro	0.633	0.737	+0.105, significativa (IC 95%: +0.005 a +0.205)
Máscaras, F1 / mAP50-95	0.778 / 0.488	0.783 / 0.497	similar
Acierto de categoría OCDE	77.8%	77.8%	sin diferencia (IC 95%: -7.5 a +8.3 pts)

1. Objetivo y alcance

El objetivo específico asociado es ampliar y robustecer el conjunto de datos de entrenamiento mediante pseudo-etiquetado semisupervisado con el propio modelo. La metodología del roadmap define tres pasos: generar pseudo-etiquetas con el modelo entrenado, revisar y validar las nuevas imágenes etiquetadas, y reentrenar con el dataset ampliado. Este informe documenta los tres pasos, más la reconstrucción previa del modelo base, que era condición necesaria porque el trabajo de Seminario I dependía de Roboflow y no clasificaba madurez.

2. Reconstrucción del modelo base

2.1 Datos

El dataset original (Hass Avocado Ripening Photographic Dataset) contiene 14,710 fotografías de 800 × 800 píxeles de 478 paltas, tomadas en caja de luz a lo largo de varios días y por ambos lados del fruto, en tres condiciones de almacenamiento (T10, T20 y ambiente). El nivel de madurez de 1 a 5 viene codificado en el

nombre de cada archivo. De ese total, 1,243 imágenes tenían polígonos de palta y defecto generados en Seminario I con SAM2.

2.2 Partición por fruto

La partición de Roboflow usada en Seminario I se hizo por imagen. Como cada palta aparece en varias fotos, 198 de las 415 paltas anotadas quedaban repartidas entre entrenamiento, validación y prueba. En esas condiciones el modelo se evalúa con frutos que ya vio, lo que infla las métricas, especialmente la de madurez. La nueva partición agrupa todas las fotos de una palta en un solo subconjunto (StratifiedGroupKFold, 10 pliegues: 7 de entrenamiento, 2 de validación y 1 de prueba, semilla 42) y mantiene balanceados los cinco niveles de madurez. Las 63 paltas nunca anotadas se asignaron con el mismo procedimiento.

Subconjunto	Paltas	Imágenes anotadas usadas	Fotos totales del dataset
Entrenamiento	340	852	10,736
Validación	94	232	2,834
Prueba	44	108	1,140

Las imágenes anotadas usadas excluyen las 51 anotaciones defectuosas. Prueba conserva 39 paltas con anotación humana (108 imágenes).

2.3 Auditoría de anotaciones

Se identificaron y excluyeron 51 anotaciones (4.1%) con errores imposibles en una anotación correcta: 24 con el polígono de palta reducido a una mancha de pocos píxeles o con un área de defecto mayor que la del fruto, y 27 con el defecto dibujado como el rectángulo de respaldo que el script de Seminario I usaba cuando SAM2 fallaba. Estas últimas eran especialmente dañinas, porque el modelo aprendía a dibujar defectos rectangulares. La exclusión no altera la partición; la lista queda documentada en `data/splits/anotaciones_excluidas.csv`.

2.4 Arquitectura

El modelo es YOLOv8s-seg, inicializado con pesos preentrenados en COCO, extendido con un cabezal de clasificación de madurez conectado a la salida de la capa SPPF del backbone. El backbone es compartido: el gradiente de ambas tareas lo actualiza, por lo que se trata de un modelo multitarea y no de dos modelos. El cabezal de madurez añade 0.13 millones de parámetros a un total de 11.92 millones.




Figura 1. Arquitectura del modelo multitarea y post-proceso OCDE.

2.5 Decisiones de diseño

- **overlap_mask desactivado.** Con el valor por defecto de Ultralytics, la máscara de palta quedaba con huecos donde había defectos, mientras que el polígono anotado cubre el fruto completo. Al desactivarlo, la palta se aprende como fruto completo.
- **Sin mosaic ni mixup.** Estas técnicas mezclan varias imágenes en una, lo que produciría imágenes con paltas de distinta madurez y una sola etiqueta.
- **Variación de color moderada.** La madurez de la palta Hass se expresa en el color de la cáscara, por lo que la saturación y el brillo se perturban menos que en Seminario I.
- **Peso de la tarea de madurez $\lambda = 2$.** Elegido en validación frente a $\lambda = 1$: mejoró la madurez sin perjudicar la segmentación.
- **Umbral de defecto calibrado en validación.** Palta con confianza 0.35 (umbral de Seminario I) y defecto con el umbral que maximiza el IoU de defecto en validación, nunca elegido en prueba.

3. Pseudo-etiquetado

Flujo de la Etapa 1: ampliación del dataset mediante pseudo-etiquetado

Fila superior: preparación y modelo base (reconstrucción de Seminario I). Fila inferior: pseudo-etiquetado y reentrenamiento.




Figura 2. Flujo completo de la Etapa 1.

3.1 Generación

El modelo base predijo las máscaras de las 9,892 fotos de paltas de entrenamiento sin anotación humana. Las fotos de paltas de validación y prueba no se pseudo-etiquetaron, para no introducir fuga. La madurez no requiere pseudo-etiqueta porque es conocida para todas las fotos. La palta se detectó con confianza mínima de 0.96 en todas las imágenes; toda la incertidumbre se concentró en los defectos.

3.2 Regla de aceptación calibrada

Revisar manualmente las 5,500 fotos con defectos dudosos habría requerido entre 4 y 5 horas. En su lugar, la regla de aceptación se calibró sobre las 232 imágenes de validación, donde existe anotación humana y se puede medir la calidad de lo que se aceptaría. Una foto se acepta si el área de sus defectos con confianza menor a 0.5 no supera el 50% del área de defecto total y no contiene defectos rectangulares.

Regla (confianza mínima / área dudosa máxima)	Fotos aceptadas	Precisión defecto	Recall defecto	Acierto OCDE
0.15 / hasta 50% (elegida)	55%	0.853	0.494	85.0%
0.15 / sin límite	97%	0.581	0.651	75.0%
0.30 / hasta 50%	75%	0.869	0.337	79.2%
0.50 / sin límite	100%	0.843	0.194	70.7%

Aplicada a entrenamiento, la regla aceptó 4,623 de las 9,892 fotos (47%). La limitación conocida desde la calibración es que las pseudo-etiquetas aceptadas son precisas pero incompletas: cubren aproximadamente la mitad del área dañada real.



Figura 3. Izquierda: pseudo-etiqueta aceptada automáticamente (foto original y pseudo-etiqueta). Derecha: foto descartada en esta ronda por concentrar su área de defecto en predicciones de baja confianza.

4. Parámetros de entrenamiento

Parámetro	Valor	Parámetro	Valor
Modelo inicial	yolov8s-seg.pt (COCO)	Tamaño de imagen	800 px
Épocas máx. / paciencia	100 / 20	Batch	8
Optimizador	AdamW (selección automática), lr $\approx$ 0.0017	Warmup	3 épocas
Weight decay	0.0005	Semilla	42 (determinista)
mosaic / mixup / cutmix	0 / 0 / 0	overlap_mask	False
hsv_h / hsv_s / hsv_v	0.01 / 0.4 / 0.3	Rotación / traslación / escala	15° / 0.1 / 0.5
Volteo vertical / horizontal	0.5 / 0.5	Peso madurez (λ)	2
Selección del mejor modelo	0.5 $\times$ (0.1 mAP50 + 0.9 mAP50-95 de máscaras) + 0.5 $\times$ F1 macro de madurez, en validación		
Hardware	NVIDIA RTX A5000 Laptop (16 GB), Intel i7-11800H, 32 GB RAM		

Modelo	Imágenes de train	Épocas (mejor)	Tiempo	Umbral defecto
Modelo base	852	89 (69)	30 min	0.15
Ronda 1	5,475	77 (57)	2 h 27 min	0.05

5. Resultados

5.1 Validación durante el entrenamiento




Figura 4. Evolución en validación. La ronda 1 alcanza antes un nivel superior de madurez y oscila bastante menos entre épocas; en segmentación termina en un nivel similar al del modelo base.

Validación (mejor época)	Modelo base	Ronda 1
Precisión / recall de máscaras	0.810 / 0.751	0.811 / 0.765
mAP50 / mAP50-95 de máscaras	0.770 / 0.642	0.783 / 0.649
Madurez: exactitud / F1 macro	70.7% / 0.707	75.0% / 0.741

5.2 Prueba

La evaluación final se hizo sobre las mismas 108 imágenes de prueba (39 paltas) para ambos modelos, con el umbral de defecto calibrado en validación para cada uno. Los intervalos de confianza al 95% se estimaron con 2,000 remuestreos bootstrap por fruto; para la diferencia entre modelos se usó bootstrap pareado.

Métrica (test)	Modelo base	Ronda 1	IC 95% ronda 1
Máscaras: precisión / recall	0.829 / 0.734	0.794 / 0.771	
Máscaras: F1 / mAP50 / mAP50-95	0.778 / 0.783 / 0.488	0.783 / 0.780 / 0.497	
mAP50 máscara: palta / defecto	0.977 / 0.589	0.978 / 0.581	
IoU por píxel: palta / defecto	0.996 / 0.420	0.994 / 0.397	
Madurez: exactitud	63.9%	74.1%	67.3 a 80.9%
Madurez: F1 macro	0.633	0.737	0.664 a 0.804
Madurez con tolerancia de ± 1 nivel	100%	100%	100%
Acierto categoría OCDE	77.8%	77.8%	66.4 a 87.8%
Recall de "Rechazado"	64.3%	60.7%	33.3 a 82.9%
Error del ratio defecto/palta (MAE)	0.072	0.075	0.044 a 0.109

F1 por nivel de madurez (test)	1	2	3	4	5
Modelo base	0.864	0.667	0.412	0.538	0.683
Ronda 1	0.889	0.739	0.711	0.680	0.667




Figura 5. Matrices de confusión de madurez en prueba: modelo base (izquierda) y ronda 1 (derecha). En ambos casos todos los errores son de un solo nivel; la mayor ganancia está en el nivel 3, que pasa de 7 a 16 aciertos.

5.3 Comparación con Seminario I

El YOLOv8s de Seminario I reportó precisión 0.801, recall 0.763, F1 0.781, mAP50 0.785 y mAP50-95 0.557. El modelo actual obtiene valores equivalentes en precisión, recall, F1 y mAP50, y además clasifica madurez. La comparación directa favorece a Seminario I, porque su partición por imagen permitía que la misma palta estuviera en entrenamiento y en prueba.

5.4 Ejemplos

Cada figura muestra la foto original, la anotación humana y la predicción del modelo de la ronda 1, con la madurez y la categoría OCDE resultantes.



Figura 6. Acierto en una palta rechazada (madurez 1): el modelo detecta las dos zonas dañadas, la raspadura y el grupo de lenticelas dañadas, y la clasifica como Rechazado (17.3% frente a 23.5% real). La zona de manchas aún se dibuja con contorno casi rectangular, un rastro de las anotaciones de respaldo de Seminario I.




Figura 7. Acierto en Categoría I con una grieta corchosa (madurez 3): el contorno predicho sigue de cerca la anotación y el área estimada coincide (5.3%).



Figura 8. La misma palta de la figura 7 fotografiada días después, ya en madurez 5. El modelo mantiene la segmentación del defecto con la cáscara oscura y clasifica la madurez con 94% de confianza.




Figura 9. Error típico: una palta rechazada (25.6% de área con defecto) clasificada como Categoría I. El modelo no reconoce la zona de manchas de la parte superior, que corresponde a lenticelas dañadas, y marca solo una pequeña zona inferior (3.2%). Es el tipo de error que motivan la guía de anotación y la corrección dirigida de la sección 7.




Figura 10. Matriz de confusión OCDE en prueba (ronda 1).

6. Discusión

La mejora en madurez proviene de etiquetas reales. Las 4,623 imágenes añadidas multiplicaron por seis los ejemplos de madurez, y esa etiqueta es exacta porque proviene del diseño del dataset. En cambio, las máscaras de defecto de esas imágenes eran pseudo-etiquetas incompletas. El resultado es coherente con esa asimetría: la tarea con más etiquetas reales mejoró de forma significativa, y la tarea con etiquetas aproximadas no cambió.

El pseudo-etiquetado desplazó la confianza de los defectos. Al entrenar con máscaras que omiten parte del daño, el modelo aprendió a detectar defectos con menor confianza: el umbral óptimo en validación bajó de 0.15 a 0.05. La recalibración compensa el efecto, pero es un hallazgo a reportar, porque implica recalibrar el umbral después de cada ronda y porque el efecto podría acumularse si se repiten rondas automáticas sin mejorar las etiquetas de defecto.

La conclusión sobre la segmentación es que no empeoró. Todas las diferencias en máscaras y OCDE están dentro del margen de error; el diseño de la regla de aceptación evitó que las pseudo-etiquetas degradaran

el modelo.

Limitaciones. (1) El conjunto de prueba tiene 39 paltas, lo que produce intervalos amplios, sobre todo en el recall de rechazados. (2) Todas las imágenes son de caja de luz con fondo blanco; el desempeño en fotos de celular en condiciones reales no está medido. (3) El criterio de qué constituye defecto, en particular las lenticelas dañadas, no está formalizado en una guía de anotación. (4) El sistema no mide calibre ni peso, que la norma OCDE también contempla. (5) La latencia medida en la GPU de la laptop (20 a 36 ms por imagen) no representa la latencia en un celular.

7. Lo que se espera

7.1 Cierre de la Etapa 1

- **Guía de anotación.** Definir por escrito qué es defecto según la norma Codex/OCDE (lenticelas dañadas, suberización, golpes, raspaduras, quemaduras) y qué no (lenticelas sanas, textura y oscurecimiento natural por madurez), con ejemplos.
- **Corrección dirigida.** Corregir manualmente unas 200 imágenes con defectos incompletos, con asistencia de SAM, para aportar las etiquetas de defecto que el pseudo-etiquetado no provee.
- **Ronda 2.** Regenerar pseudo-etiquetas con el modelo de la ronda 1 e incorporar las correcciones. Se espera un mayor porcentaje de aceptación automática y, principalmente, una mejora en el recall de defectos. Se detendrán las rondas cuando la ganancia en validación sea menor a uno o dos puntos.

7.2 Etapas siguientes

- **Etapa 2, cuantización.** Exportar el mejor modelo a formato móvil con sus dos salidas y comparar FP32, FP16 e INT8 a 800 y 640 píxeles, en precisión y latencia. Se espera reducir el modelo de 24 MB a unos 6 MB con pérdida pequeña de precisión.
- **Etapa 3, prototipo.** Aplicación Android construida a partir de las historias de usuario definidas (productor o acopiador y operario de packing), con análisis sin conexión y resultado en 2 segundos o menos.
- **Etapa 4, integración.** Motor OCDE y madurez dentro de la aplicación, validado contra los resultados de Python.
- **Etapa 5, validación.** Latencia en el dispositivo, robustez a iluminación y, como riesgo principal, desempeño con fotos reales de celular. Se recomienda adelantar una prueba con 50 a 100 fotos reales.

Anexo: reproducibilidad

Todo el pipeline está en palta-multitarea/scripts y se ejecuta localmente, sin Roboflow.

Paso	Script
Partición por fruto	<code>split_dataset.py</code>
Auditoría de anotaciones	<code>auditar_anotaciones.py</code>
Dataset en formato YOLO	<code>prepare_yolo.py</code>
Entrenamiento multitarea	<code>train_yolo_multitarea.py --sin-overlap --peso-madurez 2</code>
Calibración del umbral de defecto	<code>calibrar_umbral_defecto.py</code>
Calibración de la regla de pseudo-etiquetas	<code>calibrar_regla_pseudo.py</code>
Pseudo-etiquetado	<code>generar_pseudoetiquetas.py</code>
Dataset ampliado	<code>armar_dataset_ampliado.py</code>
Evaluación en prueba	<code>eval_yolo_multitarea.py</code>
Intervalos de confianza	<code>bootstrap_ic.py</code>
Visor y revisión manual	<code>visor.py</code> , <code>revisor.py</code>

Modelo de la ronda 1: `resultados/yolo_multitarea/yolov8s_mt_ronda1/weights/best.pt`. Ultralytics 8.4.160, PyTorch con CUDA 12.6.